Workshop

```
Data
yelp_academic_dataset_business.json
    "business_id": "encrypted business id",
    "name": "business name",
    "neighborhood": "hood name",
    "address": "full address",
    "city":"city",
    "state": "state -- if applicable --",
    "postal code": "postal code",
    "latitude":latitude,
    "longitude":longitude,
    "stars":star rating, rounded to half-stars,
    "review_count":number of reviews.
    "is_open":0/1 (closed/open),
    "attributes":["an array of strings: each array element is an
attribute"],
    "categories": ["an array of strings of business categories"],
    "hours":["an array of strings of business hours"],
    "type": "business"
}
yelp_academic_dataset_review.json
{
    "review_id": "encrypted review id",
    "user_id": "encrypted user id",
    "business_id": "encrypted business id",
    "stars":star rating, rounded to half-stars,
    "date": "date formatted like 2009-12-19",
    "text": "review text",
    "useful":number of useful votes received,
    "funny":number of funny votes received,
    "cool": number of cool review votes received,
    "type": "review"
}
yelp_academic_dataset_user.json
{
    "user_id": "encrypted user id",
```

```
"name":"first name",
    "review_count":number of reviews,
    "yelping_since": date formatted like "2009-12-19",
    "friends":["an array of encrypted ids of friends"],
    "useful": "number of useful votes sent by the user",
    "funny": "number of funny votes sent by the user",
    "cool": "number of cool votes sent by the user",
    "fans": "number of fans the user has",
    "elite":["an array of years the user was elite"],
    "average_stars":floating point average like 4.31,
    "compliment_hot":number of hot compliments received by the
user,
    "compliment_more":number of more compliments received by the
user,
    "compliment_profile": number of profile compliments received
by the user,
    "compliment_cute": number of cute compliments received by the
user,
    "compliment_list": number of list compliments received by the
    "compliment_note": number of note compliments received by the
user,
    "compliment_plain": number of plain compliments received by
the user.
    "compliment_cool": number of cool compliments received by the
    "compliment_funny": number of funny compliments received by
the user,
    "compliment_writer": number of writer compliments received by
    "compliment_photos": number of photo compliments received by
the user,
    "type": "user"
}
yelp academic dataset checkin.json
    "time":["an array of check ins with the format day-
hour:number of check ins from hour to hour+1"],
    "business_id": "encrypted business id",
    "type": "checkin"
}
```

```
yelp_academic_dataset_tip.json
{
    "text":"text of the tip",
    "date":"date formatted like 2009-12-19",
    "likes":compliment count,
    "business_id":"encrypted business id",
    "user_id":"encrypted user id",
    "type":"tip"
}
```

Idées :

- Déterminer la recette des restaurants pour trouver les caractéristiques d'un bon restaurant -> compliqué
- Déterminer l'humeur, la situation sociale du client en fonction du restaurant (nom, etc ...) qu'il fréquente, de la météo
- l'ambiance du quartier en fonction des mots clés dans catégorie
- Déterminer si le client est prêt à faire des km pour avoir un bon restaurant
- Déterminer la probabilité qu'un client aille au restaurant en sachant qu'un certain nombre de ses amis y soient déjà allé + ses commentaires, ses conseils
- Savoir si le goût est le même ou différent entre amis : restaurants fréquentés, commentaires postés, conseils donnés
- Chercher pourquoi un restaurant est fermé : trouver les caractéristiques

```
Choix: La météo influence t'elle la notation des clients ?

Données utilisées :

-User -> Id, average stars,

-review -> Business, Stars, user, date, type

-Business -> city, longitude & latitude

-New dataset -> météo -> date, city, temps
```

To do:

- Créer le dataset contenant les données météorologiques : chercher l'api, et créer le fichier sous le format « json »
- -Rechercher les «rating» de l'utilisateurs X qui sont inférieur à sa moyenne
 - -Mettre en concordance avec la météo du jour recherchée Catégoriser par type de business

- Prédire les futurs notation des clients

-Idée:

-Déterminer la probabilité qu'un client aille au business en fonction du rating du client.

-Prédiction future rating

-Données utilisées:

-User : id, friends

-Review: user_id, stars, business_id

- business : id, stars

Influence des amis, qui écouter ?

To Do:

- Create graphFrames

Pour chaque business :

- Récupérer la date + id_business, analyser si ses amis sont déjà allés auparavant.
 - Si oui, calculer la moyenne rating de tous ses amis.
 - Si Moyenne rating >3 => Bon business => Personne
 influençable

On peut prédire son future rating

- Sinon mauvais => N'ecoute pas ses amis
 - Analyser son rating
- Si non, voir si ses amis sont y allés après lui.

Fin pour, Savoir si une personne est influençable ou non